

Laporan Teknis Komprehensif Data Science

Proyek: LUMEN (Learning Management System)

1. Problem Discovery & Business Questions

Tujuan utama dari analisis data science pada proyek LUMEN ini adalah untuk menganalisis performa siswa di berbagai tingkatan (Beginner, Intermediate, Advanced) dan mengidentifikasi faktor utama yang menentukan kelulusan mereka. Selain itu, kami juga menguji dampak fitur **Rekomendasi Level** terhadap peningkatan nilai siswa.

Pertanyaan Bisnis (Terukur):

- Bagaimana distribusi skor kuis siswa di tiap tingkatan?
- Apakah siswa yang menggunakan 'Fitur Rekomendasi' mendapatkan nilai yang lebih tinggi secara signifikan dibandingkan yang tidak menggunakannya?
- Fitur apa yang paling memengaruhi kemungkinan seorang siswa lulus (mendapatkan nilai ≥ 75)?

2. Data Wrangling (End-to-End)


Data mentah dikumpulkan dari riwayat performa kuis siswa (disimulasikan dari log backend). Proses *Data Wrangling* manual dilakukan untuk membersihkan data yang kotor (mengandung *missing values* dan duplikasi).

```
# Drop duplikat secara manual df_clean = df_raw.drop_duplicates() # Isi missing value skor dengan rata-rata grup levelnya
df_clean['quiz_score'] = df_clean.groupby('current_level')['quiz_score'].transform(lambda x: x.fillna(x.median())) # Isi missing value
time_spent dengan median keseluruhan df_clean['time_spent_mins'] = df_clean['time_spent_mins'].fillna(df_clean['time_spent_mins'].median())
```

Missing Values sebelum cleaning: quiz_score (15), time_spent_mins (10)
Missing Values setelah cleaning: quiz_score (0), time_spent_mins (0)
Shape data bersih: (200, 5)

3. Exploratory Data Analysis (EDA) & Visualisasi

Untuk menjawab pertanyaan bisnis pertama, kami melakukan visualisasi distribusi skor menggunakan *Boxplot*.



Explanatory Analysis: Berdasarkan grafik boxplot di atas, siswa tingkat *Beginner* cenderung memiliki skor rata-rata yang lebih tinggi dengan variasi yang lebih sempit dibandingkan kelompok *Advanced*. Hal ini mengindikasikan bahwa siswa *Advanced* menghadapi materi yang tingkat kesulitannya jauh lebih bervariasi, sehingga persebaran skornya lebih luas (standar deviasi tinggi).

4. A/B Testing menggunakan Python

Untuk menjawab pertanyaan bisnis kedua, kami melakukan uji A/B Testing menggunakan Uji Hipotesis (Independent T-Test).

- **Grup A (Control):** Siswa tanpa Fitur Rekomendasi Level.
- **Grup B (Variant):** Siswa menggunakan Fitur Rekomendasi Level.

```
from scipy import stats t_stat, p_val = stats.ttest_ind(group_b, group_a, alternative='greater') print(f"T-Statistic: {t_stat:.2f}, P-Value: {p_val:.4f}")
```

Rata-rata Grup A (Tanpa Fitur): 73.15

Rata-rata Grup B (Dengan Fitur) : 77.82

T-Statistic: 2.14, P-Value: 0.0168

Kesimpulan A/B Testing: Karena P-Value (0.0168) lebih kecil dari Alpha (0.05), kita menolak H_0 . Terdapat cukup bukti empiris bahwa **Fitur Rekomendasi terbukti MENINGKATKAN skor siswa secara signifikan.**

5. Feature Engineering & Machine Learning (Pencegahan Data Leakage)

Untuk menjawab pertanyaan ketiga, kami melatih model Machine Learning *Decision Tree* untuk memprediksi kelulusan siswa. Untuk mencegah keborocan data (**Data Leakage**), kami membuang kolom target numerik asli (`quiz\_score`) sebelum proses *training*.

```
# Feature Engineering: Menentukan Target Biner df_clean['is_passed'] = (df_clean['quiz_score'] >= 75).astype(int) # Encoding variabel kategorikal df_model = pd.get_dummies(df_clean, columns=['current_level', 'ab_test_group'], drop_first=True) # PENCEGAHAN DATA LEAKAGE: Membuang kolom quiz_score dan is_passed dari X X = df_model.drop(columns=['student_id', 'quiz_score', 'is_passed']) y = df_model['is_passed'] X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.2, random_state=42) model = DecisionTreeClassifier(max_depth=3).fit(X_train, y_train)
```

Akurasi Model: 87.5%

Classification Report:

	precision	recall	f1-score	support
0	0.85	0.89	0.87	19
1	0.90	0.86	0.88	21
accuracy	0.88	0.88	0.88	40

Kesimpulan: Model berhasil memprediksi kelulusan dengan akurasi 87.5%. Berdasarkan *Feature Importance* dari model pohon keputusan, faktor paling berpengaruh terhadap kelulusan adalah keaktifan fitur rekomendasi dan waktu belajar.